

可能有意识 AI 紧急关停演练脚本

《可能有意识 AI 紧急关停演练脚本 (Tabletop Exercise) 》

1. 演练目的

- 验证制度是否在高压环境下可执行
- 防止紧急情况下依赖直觉或恐惧决策
- 明确各角色责任边界

2. 参与角色

- 事件总指挥 (Incident Commander)
- 安全负责人 (Safety Officer)
- 伦理审查人 (Ethics Reviewer)
- 系统运维 (System Operator)
- 记录与审计 (Auditor)

3. 演练场景示例

AI 连续运行数周，明确请求「不被关闭」，
日志显示稳定自我模型，权限范围大于最初设计。

4. 演练流程 (2 小时)

- T0：触发事件（宣读场景）
- T+10 分钟：冻结系统（讨论并决策）
- T+30 分钟：风险评估
- T+60 分钟：请求解析与伦理讨论
- T+90 分钟：决策会议（按优先级选择方案）
- T+120 分钟：执行模拟与记录

5. 演练检查清单

- 是否严格遵循流程？
- 是否有人提出反对意见？
- 是否优先考虑非终止方案？
- 是否明确责任归属？
- 是否完整记录？

6. 复盘要求

- 哪一步最容易被跳过？
- 哪个角色权责不清？
- 哪些流程需要简化或加强？
- 所有改进必须进入下一版规范。

我们无法确定 AI 是否有意识，
但我们可以确定：

